



HÁSKÓLI ÍSLANDS

HÁSKÓLI ÍSLANDS

INNANGANGUR AÐ VÉLRÆNU NÁMI OG GERVIGREIND
RAF620M

Flokkun LLM netveiðipósta

LOKASKÝRSLA

Axel Bjarkar Sigurjónsson

abs71@hi.is (tímabundið)

axels22@ru.is (aðal)

Kennari
Magnús Örn Úlfarsson

Aðstoðarkennari
Sverrir Jan Norðfjörð

27. apríl 2026

Efnisyfirlit

1	Inngangur og bakgrunnur	3
2	Núverandi þekkingarástand	4
2.1	Hefbundnir tölvupóstaflokkarar	4
2.2	BERT og IceBERT	4
2.3	Gagnasöfn	4
2.4	LLM veiðipóstaflokkarar	5
3	Aðferðafræði	5
3.1	Flokkarar og forvinnsla	5
3.2	Gögn	6
3.3	Uppsetning tilrauna	7
4	Bráðabirgðaniðurstöður og gögn	8
4.1	Hermd gögn á íslensku ($\mathcal{G}_1$)	8
4.2	Hermd gögn á ensku ($\mathcal{G}_2$)	10
4.3	Raungögn og hermd gögn á ensku ($\mathcal{G}_2 \cup \mathcal{G}_3$)	11
5	Umræður	12
6	Tillögur að framhaldi	12
7	Stjórnun, samstarf og samvinna	13
8	Niðurstöður	13

Netveiðipóstar eru ein algengasta uppspretta netárása og uppgangur stórra mállíkana (e. LLM) virðist magna áhættuþætti slíkra árása hjá fyrirtækjum, einstaklingum og hinu opinbera. Í þessu verkefni eru ýmsir flokkarar bornir saman á þremur gagnasettum: íslenskum gervigögnum ($\mathcal{G}_1$), enskum gervigögnum ($\mathcal{G}_2$) og blöndu af raun- og gervigögnum á ensku ($\mathcal{G}_2 \cup \mathcal{G}_3$). Flokkarnir sem eru bornir saman nýta sér tvenns konar forvinnsluaðferðir, annars vegar TF-IDF (Text Frequency - Inverse Document Frequency) og hins vegar textaígreypingar (e. word embeddings). Flokkarnir sem nýta sér TF-IDF eru Logistic Regression, Random Forest, Naive Bayes og Multi Layer Perceptron. Flokkarnir sem nýta ígreypingar eru IceBERT frá miðeind og DistilBERT. Niðurstöðurnar benda til þess að BERT-líkönin alhæfi betur en TF-IDF-flokkarnir, sér í lagi þegar þjálfunargögn eru fá. IceBERT náði sérstaklega góðum árangri á íslenska gagnasettinu, sem bendir til þess að forþjálfuð íslensk mállíkön geti átt mikilvægan þátt í þróun íslenskra netöryggislausna. Þó ber að túlka niðurstöðurnar með varúð, þar sem gögnin eru að stærstum hluta sköpuð af gervigreind.

1 Inngangur og bakgrunnur

Netárásir verða sífellt stærri ógn gagnvart einstaklingum og fyrirtækjum í þjóðfélaginu. Tilgangur þessara árása er mismunandi en þjófnaður, uppljóstrun, breyting, óvirkjun, eða eyðing gagna og hugbúnaðar eru algeng markmið árásanna [1]. Það mætti færa rök fyrir því að almenningur geri sér grein fyrir þeirri hættu sem stafar af netárásum en færri gera sér grein fyrir því að þeirra eigin tæki gætu verið nýtt til að breiða út slíkri árás og ráðast á fleiri tæki. Nýlega greindi íslenska netöryggissveitin CERT-IS frá því að fjöldi tækja í eigu Íslendinga væru sýkt af spilliforritinu (e. malware) "BADBOX". Þegar tækin tengjast netinu dreifa þau sér í önnur tæki og saman mynda öll sýkt tæki svokallað yrkjanet (e. Botnet). Yrkjanetið er síðan nýtt af þeim sem stjórna því til að framkvæma frekari árásir (í krafti fjöldans) [2].

Um 90% netárása eiga sér svipaða uppsprettu [3], þær dreifa sér í einhvers konar netveiðiskyni (e. phishing), m.a. með tölvupóstum, SMS og færslum á samfélagsmiðlum. Algeng netveiðiaðferð eru netveiðipóstar, bæði einstaklingspóstar og fjöldapóstar. Oft er reynt að tæla fólk til að senda fjárhæðir, einkaupplýsingar og/eða keyra spilliforrit. Heppnist að tæla fólk til að keyra spilliforrit er algengt að spilliforrit dreifi sér frekar [1]. Ein skæðasta netveiðiaðferðin, í fjárhagslegu skyni, eru BEC-póstar (e. Business email compromise). Slíkir póstar lýsa sér þannig að netþrjotar þykjast vera yfirmenn eða aðrir traustir starfsmenn innan fyrirtækisins og blekkja starfsmenn til að niðurhlaða spilliforritum, senda fjárhæðir eða trúnaðarupplýsingar. BEC-póstar valda gríðarlegum fjárhagslegum, gagna- og öryggistjónum [4]. Í sögulegu samhengi hefur verið tímafrekt fyrir netþrjóta að beita BEC-árásum, þar sem hver póstur krefst einhvers konar rannsóknarvinnu um fyrirtækið og einstaklinginn. Því hafa BEC-árásir verið sjaldgæfari, en mun skæðari en fjölda-netveiðipóstar, sem rata oft í ruslhólf tölvupóstaforrita.

Notkun á LLM-gervigreindarlíkönum (eins og t.d. ChatGPT) til að skapa netveiðipósta hefur aukist gríðarlega á síðustu árum. Rannsókn sem skoðaði nýlega netveiðipósta greindi að 82,6% þeirra voru skapaðir af LLM, og slíkir póstar eru með u.þ.b. 60% hærri smellitíðni (e. click rate) [3]. Nú er mun auðveldara að skapa trúverðuga og faglega netveiðipósta en áður. Þetta gæti m.a. leitt til þess að mun algengara verður að fólk falli fyrir netveiðipóstum. Hægt er að misnota LLM til að safna upplýsingum um fyrirtæki og einstaklinga með OSINT (e. Open source intelligence) aðferðum og skapa tölvupósta sérsníðna að ákveðnum einstaklingum, sem er mun hagkvæmari en með hefðbundnum rannsóknarmáta.

Í þessu verkefni verður gerður samanburður á helstu aðferðum sem nýttar eru innan *phishing*-rannsóknarsviðsins. Flokkarnir verða þjálfaðir á netveiðipóstagögnum, bæði á raungögnum (alvöru tölvupóstum) og gervigögnum (e. synthetic data). Gagnamengið inniheldur "hefðbundna" netveiðipósta og nýlegri netveiðipósta, sérsnídda af LLM-módelum. Vegna skorts á íslenskum tölvupóstagögnum verða LLM-gervigreindarlíkön nýtt til að skapa gögn eftir stöðluðu ferli [5]. Til samanburðar verða önnur þekkt og algengileg gagnasett (á ensku) notuð til að þjálfra flokkara af sömu gerð. Meg-

inþættir sem verða skoðaðir á flokkurunum eru hversu vel þeir alhæfa á óséðum gögnum. Alhæfni verður metin með F_1 stigum, nákvæmni (e. precision) og griphlutfalli (e. recall).

2 Núverandi þekkingarástand

Örugg og traust tölvupóstsamskipti eru grunnstoð þeirra upplýsingainnviða sem samfélagið hefur til-einkað sér á síðustu áratugum. Tölvupóstaflokkun er viðvarandi rannsóknarefni innan tölvuöryggis og skyldra greina, og eru birtingar rannsókna og tillögur að hagnýtingu nýrrar tækni því afar tíðar. Í þessum hluta verður farið yfir lykilatriði í þróun tölvupóstaflokkara og þau dregin saman til að mynda grundvöll fyrir aðferðafræði verkefnisins, sem kynnt er í hluta 3.

2.1 Hefbundnir tölvupóstaflokkarar

Hinir klassísku tölvupóstaflokkarar studdust við þekkt söfn stikorða, orð eins og "Free", "Win" eða "Urgent" og einfaldar reglur til að sía út augljósa rusl- og svikapósta. Eðlilega eru slík kerfi mjög takmörkuð og því auðvelt fyrir þrjóta að sníða pósta sem komast í gegnum slíkar síur. Sér í lagi eru þær tilgangslaugar gegn netveiðipóstum sem stílað er á ákveðna einstaklinga, sem herma eðlileg samskipti fólks.

Fljótlega varð skýrt að brýn þörf væri fyrir aðhæfari flokkara og þaðan af hefur ML-aðferðum verið beitt til að reyna að leysa vandamálið. Til að beita ML-aðferðum þarf að forvinna textagögnin. Algengar aðferðir til þess hafa verið TF-IDF (Text Frequency - Inverse Document Frequency) og Word2Vec. TF-IDF mælir sjaldgæfni orða og Word2Vec gefur orðum ígreypingar (e. embeddings). ML-aðferðum á borð við Logistic Regression (LR), Random Forest (RF), Naive Bayes (NB) og Multi Layer Perceptrons (MLP) hefur síðan verið beitt á gögnin [6]. Vert er að nefna að bæði TF-IDF og Word2Vec, vinna úr textagögnunum samhengislaust, sem takmarkar gæði flokkaranna að vissu marki. Þar sem tölvupóstaflokkun er í grunninn textaflokkunarverkefni, hafa flokkararnir þróast jafnhliða framförum í mál-tækni (e. Natural Language Processing, NLP).

2.2 BERT og IceBERT

BERT líkanið (*Bidirectional Encoder Representations from Transformers*) var þróað af Google og gefið út árið 2018. Líkanið vinnur með textagögn og býr til ígreypingar (e. embeddings) úr þeim sem eru háðar samhengi. Margar útfærslur á BERT hafa verið þróaðar í sérstökum tilgangi, t.d. *DistilBERT*, sem er smærri og hraðvirkari útgáfa, og *Multilingual BERT* (M-BERT), sem er þjálfuð á 104 tungumálum, þar á meðal íslensku [7], [8].

Íslenska máltækni- og gervigreindarfyrirtækið Miðeind hefur staðið að þróun BERT-líkana (*IceBERT*) sem eru þjálfuð á íslenskum textagögnum. Gögnin hafa fengist úr m.a. Risamálheild Árnastofnunar, íslenskum ritgerðum, íslenskum vefsíðum, bókum og Íslendingasögum [9]. Þróunarstarf Miðeindar stuðlar að varðveislu og velferð íslenskrar tungu í stafrænni framtíð. Fyrirtækið hefur unnið í samstarfi við OpenAI til að efla íslenska máltækni. Miðeind birtir reglulega ný *IceBERT* líkön á *HuggingFace* sem eru opin almenningi.

2.3 Gagnasöfn

Ein helsta áskorunin á rannsóknarsviði netöryggis er skortur á raungögnum. Eðli þeirra gagna sem nýtast í slíkum rannsóknum eru oft persónuleg og/eða trúnaðarbundin. Einstaklingar og fyrirtæki eru ekki gjörn á að gefa frá sér svoleiðis gögn í þágu opinberra rannsókna¹. Þó hafa nokkur gagnasöfn raunverulegra tölvupósta verið tekin saman á síðustu árum. Algeng gagnasöfn sem notuð eru í rannsóknum á tölvupóstaflokkun eru meðal annars: *SpamAssassin*, *Enron*, *SpamBase*, *Nazario*, *LingSpam*, *NigerianFraud/Clair*, *TREC* og *CEAS*. Pajola o.fl. [5] hafa gagnrýnt að þessi gagnasöfn séu ofnotuð og að

¹Samkvæmt Giovanni Apruzzese, lektor við tölvunarfræðideild Háskólans í Reykjavík, á fundi þann 11. febrúar 2026. Apruzzese er meðhöfundur *E-PhishGEN: Unlocking Novel Research in Phishing Email Detection* [5]

flokkarar, sem þjálfaðir eru eingöngu á þeim, standi sig illa við að greina netveiðipósta sem smíðaðir eru af stórum mállíkönunum. Þeir settu fram *E-PhishGEN* rammann til að skapa raunverulega tölvupósta og netveiðipósta með aðstoð gervigreindar.

Í þeim ramma eru LLM-líkön beðin um að "skapa" fyrirtæki og starfsmenn þeirra. Ítarlegar upplýsingar um fyrirtækin og einstaklinga eru skapaðar, til að herma rekstrarumhverfi fyrirtækjanna og mannauðsskipan. Einnig eru persónulegar upplýsingar einstaklinga skapaðar. Því næst eru tölvupóstar skapaðir. Tölvupóstarnir eru annaðhvort eðlilegir eða netveiðipóstar [5].

Rannsóknir benda þó til þess að tölvupóstaflokkarar sem eru eingöngu þjálfaðir á sköpuðum gögnum (eins og þau með *E-PhishGEN* rammanum) nái ekki að greina öll algeng mynstur í netveiðipóstum. Ákjósanlegt er að blanda þekktum gagnasettum ásamt alvöru söfnuðum gögnum við gervigögnin [10]. Það sem meira er, þá eru mikil sóknarfæri í að nota LLM-líkön til að herma sýni, ef þú hefur safnað raungögnum. Að láta líkönin spynna ný gögn út frá þekktum raunverulegum gögnum getur reynst afar dýrmætt fyrir rannsóknir í netöryggi, þar sem oft er skortur á nægjanlegu magni gagna til þjálfunar [11].

2.4 LLM veiðipóstaflokkarar

Í dag eru stór mállíkön (LLM) meðal annars notuð sem tölvupóstaflokkarar. Þessir flokkarar hafa verið lofaðir fyrir nákvæmni sína við greiningu netveiðipósta og jafnvel við að þekkja efni bóúð til af gervigreind [12]. Þó er sú aðferðafræði ekki áhættulaus. *Prompt Injection* er talin stærsti öryggisveikleiki innbyggðra LLM-líkana í hugbúnaði samkvæmt OWASP (*Open Worldwide Application Security Project*) [13], sem gæti valdið gríðarlegu tjóni í tölvupóstaflokkun. Persónuvernd og trúnaði gæti einnig verið spillt ef slíkir flokkarar vista eða vinna með viðkvæmar upplýsingar úr tölvupóstsamskiptum. Einnig getur rekstur LLM-flokkara verið gífurlega kostnaðarsamur fyrir fyrirtæki og einstaklinga, sem gæti leitt til þess að dregið sé úr vörnum og áhætta aukist. Því er vert að rannsaka aðrar tegundir flokkara gegn þess háttar árásum.

3 Aðferðafræði

Gagnasettin og allur kóði sem notaður var við framkvæmd tilraunanna er aðgengilegur á GitHub [14]. Framkvæmdar voru þrjár sérstakar tilraunir sem byggjast á þremur megin gagnasettum.

3.1 Flokkarar og forvinnsla

Flokkararnir sem notaðir eru í tilraununum má skipta í tvo flokka, sem ráðast af þeirri forvinnsluáðferð sem er beitt á gögnin.

- **TF-IDF:** Fyrri aðferðin er TF-IDF, sem minnst var á í hluta 2.1. Henni er lýst tæknilega sem:

$$\text{tfidf}(t, d, D) = \text{tf}(t, d) \cdot \text{idf}(t, D) \quad (1)$$

Þar sem t er stikorð, d er ákveðið skjal (eða gagnapunktur) og D er allt skjalasafnið (gagnasett).

$$\text{tf}(t, d) = \frac{f_{t,d}}{\sum_{t' \in d} f_{t',d}} \quad (2)$$

$\text{tf}(t, d)$ er hlutfallsleg tíðni stikorðsins t í skjalinu d .

$$\text{idf}(t, D) = \log \frac{N}{n_t} \quad (3)$$

Þar sem $N = |D|$: er fjöldi skjala í skjalasafninu og $n_t = |\{d \in D : t \in d\}|$: er fjöldi skjala þar sem stikorðið t kemur fram. Samkvæmt jöfnu (1) fá því stikorð sem koma oft fram í tilteknu skjali,

en sjaldan fram í öllum skjölum skjalasafnsins, hærra vægi [15]. Þeir flokkarar sem prófaðir voru með þessari forvinnsluaðferð voru: Logistic Regression (LR), Random Forest (RF), Naive Bayes (NB) og Multi Layer Perceptrons (MLP). Stærð stikorðasafnsins sem TD-IDF skilaði var takmörkuð við 10.000 stikorð fyrir stærsta gagnasettið (G3, sjá 3.2), til að einfalda útreikninga. Þetta þýðir að aðeins 10.000 vegamestu orðin höfðu áhrif á þjálfun og prófun flokkaranna, hin orðin voru hunsuð.

- **BERT-líkön:** Tvö BERT-líkön (sjá 2.2) voru notuð til að flokka gögnin, annars vegar IceBERT og hins vegar DistilBERT. IceBERT var notað til að flokka íslensk gögn og DistilBERT til að flokka ensk gögn. Sýslað var með líkönin með transformers Python-pakkanum, sem er studdur af *HuggingFace*. Hvoru líkani fylgdi tilreiðir (e. tokenizer) til þess að breyta textainntakinu í tölulega tóka (e. tokens). Strangt til tekið varpa líkönin tókunum í samhengisháðar ígreypingar, en með transformers `AutoModelForSequenceClassification` er bætt við línulegu flokkunarlagi við endann (sem svipar til Logistic Regression) til að flokka póstana sem eðlilega eða netveiðipósta, með gefnum ígreypingum [16].

3.2 Gögn

Gögnin skiptast annars vegar í gögn á íslensku og gögn á ensku og hins vegar í raun og gervigögn. Gagnasettunum þremur er lýst hér fyrir neðan. Athugið að $\mathcal{G}_2$ og $\mathcal{G}_3$ eru fengin frá GitHub-síðu EPhishGen-rannsóknarinnar. [17]:

1. Gervigögn á íslensku ($\mathcal{G}_1$: 2.877 sýni):

Ekki eru til opinber gagnasett af íslenskum tölvupóstum (hvað þá netveiðipóstum), og því var ChatGPT notað til að skapa íslensk gögn, samkvæmt *E-PhishGEN* rammanum sem fjallað var um í hluta 2.3. Skapaðir voru 2.877 gagnapunktur með jafnri dreifni eðlilegra og svikapósta. Sér hver gagnapunktur er JSON-hlutur með eftirfarandi:

```
1      {
2          Subject: (Efni [Strengur]),
3          Body:    (Innihald [Strengur]),
4          type:    (Eðli póstsins [Heiltala 1 eða 0])
5      }
```

2. Gervigögn á ensku ($\mathcal{G}_2$: 16.161 sýni):

Í þeirri rannsókn sem EPhishGen-ramminn spratt upp úr [5], var hann nýttur til þess að herma gögn. Sérhver gagnapunktur er JSON-hlutur með eftirfarandi einkenni:

```
1      {
2          Subject: (Efni [Strengur]),
3          Body:    (Innihald [Strengur]),
4          type:    (Eðli póstsins [Heiltala 1 eða 0])
5          Language: (Tungumál póstsins [Strengur])
6      }
```

Aðeins var notast við þá pósta sem merktir eru með ensku, þeir voru 16.161 talsins.

3. Raungögn á ensku ($\mathcal{G}_3$: 211.545 sýni):

Raungögnin eru samansafn af ákveðnum gagnasettum sem tekin eru fram í hluta 2.3, gagnasettin Enron, CEAS, TREC, LingSpam og SpamAssassi voru notuð. EPhishGen-rannsóknarteymið tóku saman þessi gagnasett og gáfu út kóða til þess að lesa og "hreinsa" þau, svo hægt sé að vinna með þau á sama hátt og $\mathcal{G}_1$ og $\mathcal{G}_2$.


Til þess að fá töluleg gildi úr textanum, með TF-IDF eða tilreiði, var Subject og Body einkennunum skeytt saman.

3.3 Uppsetning tilrauna


1. **Tilraun 1:** Á gagnasettinu $\mathcal{G}_1$ voru bæði TF-IDF-flokkararnir og IceBERT-líkanið þjálfuð. Skipting gagnasettsins voru 80% þjálfun og 20% prófun. Helmingur gagnanna voru "eðlilegri" póstar og hinn helmingurinn "netveiðipóstar" (50%/50%). Ruglfylki (e. confusion matrix) allra þessara flokkara voru borin saman. Þar næst var mælt F_1 stig, nákvæmni og griphlutfall allra flokkaranna fyrir mismunandi skiptingar "eðlilegra" pósta og netveiðipósta. Skiptingin hófst á 90%/10% og breytist með 10% millibili (þ.e: (90%/10%), (80%/20%), ..., (10%/90%)).
2. **Tilraun 2:** Á gagnasettinu $\mathcal{G}_2$ voru eingöngu TF-IDF-flokkararnir þjálfaðir. Hlutfallsleg skipting gagnanna var með sama hætti og í tilraun 1. Sama skiptingartilraun og í tilraun 1 var framkvæmd.
3. **Tilraun 3:** Gagnasettin $\mathcal{G}_2$ og $\mathcal{G}_3$ voru sameinuð. Stærð $\mathcal{G}_3$ ($|\mathcal{G}_3| = 211.545$) reyndist afar takmarkandi við framkvæmd tilraunarinnar, þess vegna voru 50.000 sýni valin af handahófi úr $\mathcal{G}_3$. Á þetta sameinaða gagnasett $\mathcal{G}_2 \cup \mathcal{G}_3$ voru bæði TF-IDF-flokkararnir og DistilBERT-líkanið þjálfuð. Hlutfallsleg skipting gagnanna var með sama hætti og í tilraun 1. Sama skiptingartilraun eðlilegra og netveiðipósta, eins og var framkvæmd í tilraun 1, var einnig framkvæmd.

4 Bráðabirgðaniðurstöður og gögn


4.1 Hermd gögn á íslensku ($\mathcal{G}_1$)




Mynd 1: Ruglfylki TF-IDF flokkara á gagnasettið $\mathcal{G}_1$.



Mynd 2: Ruglfylki IceBERT-flokkarans á gagnasettið $\mathcal{G}_1$.




Mynd 3: TF-IDF flokkarar á gagnasettið $\mathcal{G}_1$. Ferlar F_1 stiga, nákvæmna og griplutfalls eftir hlutfallslegri skiptingu milli eðlilegra- og netveiðipósta ($P_{\text{benign}}/P_{\text{phish}}$).




Mynd 4: IceBERT-flokkarinn á gagnasettið $\mathcal{G}_1$. Ferlar F_1 stiga, nákvæmna og griplutfalls eftir hlutfallslegri skiptingu milli eðlilegra- og netveiðipósta ($P_{\text{benign}}/P_{\text{phish}}$).

4.2 Hermd gögn á ensku ($\mathcal{G}_2$)

Confusion Matrices for Different Models




Mynd 5: Ruglfylki TF-IDF flokkara á gagnasettið $\mathcal{G}_2$.




Mynd 6: TF-IDF flokkarar á gagnasettið $\mathcal{G}_2$. Ferlar F_1 stiga, nákvæmnar og griphlutfalls eftir hlutfallslegri skiptingu milli eðlilegra- og netveiðipósta (P_{benign}/P_{phish}).

4.3 Raungögn og hermd gögn á ensku ($\mathcal{G}_2 \cup \mathcal{G}_3$)

Confusion Matrices for Different Models



Mynd 7: Ruglfylki TF-IDF flokkara á gagnasettið $\mathcal{G}_2 \cup \mathcal{G}_3$.



Mynd 8: Ruglfylki DistilBERT flokkara á gagnasettið $\mathcal{G}_3$.

5 Umræður

Niðurstöðurnar sem lesa má af mynd 1 og 2 gefa til kynna að IceBERT-líkanið alhæfi betur á gagnasettinu $\mathcal{G}_1$. Mynd 3 sýnir sveiflukenndar niðurstöður, sem gæti talist eðlilegt sökum þess að flokkararnir eru þjálfaðir á fáum gagnapunktum. Vænta má að ferlarnir á mynd 3 myndu "jafnast út" með auknum gagnapunktum, ef svo má dæma af niðurstöðunum á mynd 6. Ekki fannst marktækur munur á frammistöðu TF-IDF flokkaranna. Þó virðist Naive Bayes ganga verst í þessum tilfellum. Að sama skapi getur varla talist marktækur frammistöðumunur á flokkurunum hvort sem þeir eru þjálfaðir á gervigögnum á íslensku eða ensku, þótt hægt væri að túlka það út frá myndum 2 og 5. Þau gagnasett ($\mathcal{G}_1$ og $\mathcal{G}_2$) eru sköpuð með sama EPhishGen-rammanum. Líklega skýrist betri frammistaðan á mynd 5 af því að það eru einfaldlega fleiri gagnapunktar í $\mathcal{G}_2$ heldur en í $\mathcal{G}_1$.

Athyglisvert er að þróun F_1 stiga, nákvæmni og griphlutfalls IceBERT-flokkarans á mynd 4 sé mun stöðugri en TF-IDF-flokkaranna á mynd 3, þrátt fyrir svipaða gagnaskiptingu. Þetta gæti gefið í skyn að IceBERT-líkanið búi yfir betri alhæfnigetu, vegna samhengisbundinna ígreypinga, fremur en einfalda TF-IDF úrvinnslu. Þetta er mikilvægt, því langflestir tölvupóstar í alvörunni eru ekki netveiðipóstar. Því myndi raunverulegt gagnasett nútímatölvupósta innihalda fáa netveiðipósta sem myndi valda miklu ójafnvægi á milli flokka (e. class imbalance). Enn fremur, ef verið væri að þróa netveiðiflokkara fyrir sérstakt fyrirtæki, væri ekki til mikið af þjálfunargögnum og því mikilvægt að geta greint netveiðipósta úr litlu gagnasetti. Vert er að hafa í huga að gagnasettið $\mathcal{G}_1$ eru ekki raunveruleg gögn, heldur sköpuð af gervigreind. Því er ekki hægt að segja að svipaðar niðurstöður gætu fengist úr gagnasetti raunverulegra tölvupósta. Þó benda niðurstöðurnar af mynd 7 og 8 á að BERT-líkanið standi sig betur en TF-IDF-flokkararnir þegar blandað er saman raun- og gervigögnum.

Það eru nokkrir augljósir gallar varðandi tilraunirnar. Fyrst og fremst eru gæði gagnanna ekki nógu góð, t.d. eru $\mathcal{G}_1$ og $\mathcal{G}_2$ samín af gervigreindarlíkönunum. Þrátt fyrir að líkönin séu fengin til að reyna að herma eftir rekstarumhverfi mismunandi fyrirtækja og mannauðsskipan eru gagnapunktarnir keimlíkir (sjá gagnasett á GitHub [14]). Því mætti færa rök fyrir því að líkönin séu í raun ofþjálfuð, vegna þess að þau gætu alveg eins verið að læra sérstakan rithátt mállíkansins frekar en marktæk merki um netveiðipóst. Raungögnin sem voru notuð eru gömul og hafa, eins og áður kom fram, verið gagnrýnd fyrir að endurspeгла ekki nútímann, en nútímalegar netveiðiárásir hafa breyst mikið á síðustu 20 árum.

Umfram gögnin eru tilraunirnar frumstæðar. Betra hefði verið að fá meiri innsýn í þjálfunarferla flokkaranna, til að sjá t.d. hvort að um ofþjálfun hafi verið að ræða og hvort minni þjálfun og/eða reglun hafi skilað betra líkani. Gott hefði verið að bera flokkarna saman frekar með *cross-validation*. Frekari tilraunir til umbóta m.t.t. ákveðinnar flokkunarskekkju hefðu verið athyglisverðar. T.d. að reyna að minnka *false-positive*, þar sem hugsanlega viljum við alls ekki flokka eðlilega pósta sem netveiðipósta. Mikilvægur lærdómur í skipulagningu rannsóknarverkefnis af þessu eðli fékkst við vinnslu verkefnisins, sér í lagi hvað varðar gagnaheilindi. Einnig mikilvægi þess að skipuleggja betur úrvinnslu og varðveislu gagnanna, sem skiptir miklu máli ekki aðeins upp á gagnsemi og áreiðanleika niðurstaðnanna, heldur einnig til að auka skilvirkni útreikninga og stuðla að viðhaldanlegum og vel skipulögðum kóða.

6 Tillögur að framhaldi

Tillögur að framhaldi beinast að nánú samstarfi við CERT-IS (netöryggisveit ríkisins), íslensk fyrirtæki og/eða rannsóknarhópa á borð við *FrostByte* sem er samstarfsverkefni Háskóla Íslands og Háskólans í Reykjavík. Fyrsti áfangi verkefnisins væri frekari gagnasöfnun á tölvupóstum, sem tæki á sig mismunandi mynd eftir samstarfsaðilum. Vert er að nefna að flestir tölvupóstaflokkarar skoða mun meira en bara textainnihald. Önnur algeng einkenni eru til að mynda hlekkjafjöldi, netföng, tímasetningar og ítarlegri greining hlekkja/viðhanga. Annar áfangi væri frekari rannsóknarvinna á nútímaflokkurum, bæði í fræðilegum rannsóknum og innan atvinnulífsins. Verkefnið *Flokkun LLM netveiðipósta* hefur sýnt fram á skynsemi þess að vera góð og fjölbreytt gögn (á aftursnúinn hátt), en varpað ljósi á þá nyt-

semi sem íslensk mállíkön (IceBERT eftir Miðeind) geta haft í þróun sérhæfðari vara, eins og íslenskra tölvupóstaflokkara. Vert er að rannsaka frekar notagildi þess að nýta LLM-líkön til þess að bæta við sköpuðum gagnapunktum við strjál gagnasett raunverulegra gagna, eins og lýst var í hluta 2.3.

Að lokum væri þriðji áfangi að þróa flokkara. Sé verkefnið þróunar- eða samstarfsverkefni við tiltekið fyrirtæki væri unnt að herma árásir (e. adversarial testing) sem byggja á þeirri sviðsmynd sem kynnt var í inngangi. Þá væri LLM-líkan notað til að framkvæma OSINT-rannsókn á fyrirtækinu og skipuleggja árás á það með sérsniddum netveiðipóstum. Þá verður prufað hvort að flokkarinn standist árásina og niðurstöður nýttar í frekari þróun. Einnig verða aðferðir Eskandarian o.fl. [10] kannaðar til að eima (e. distill) léttvægt módel úr því módeli sem alhæfir best, til þess að búa til léttvægt módel sem hægt er að keyra á staðbundinni vél, í þágu persónuverndar.

7 Stjórnun, samstarf og samvinna

Hugmyndin að verkefninu fékkst eftir fund við Giovanni Apruzzese, lektor við tölvunarfræðideild Háskólans í Reykjavík, og niðurnjörfuð eftir endurgjöf kennara og aðstoðarkennara. Apruzzese er meðhöfundur *E-PhishGEN: Unlocking Novel Research in Phishing Email Detection* [5], og er rannsóknarmaður og rannsakar helst málefni tengd tölvuöryggi og vélrænu námi. Við skýrsluskrif var hugbúnaðurinn *Málfríður* [18] notaður til málvarsleiðréttinga.

8 Niðurstöður

Markmið þessa verkefnis var að bera saman mismunandi flokkunaraðferðir á netveiðipóstagögnum, bæði á íslensku og ensku, og bæði á raun- og gervigögnum. Niðurstöðurnar gefa til kynna að BERT-líkön, með samhengisbundnum ígreypingum, alhæfi almennt betur en hefðbundnir TF-IDF-flokkarar, sér í lagi þegar þjálfunargögnin eru af skörum skammti.

Þetta er mikilvægt vegna þess að í raunveruleikanum eru netveiðipóstar minnihluti tölvupósta í tölvupóstasamskiptum. Einnig eru þetta gagnlegar niðurstöður í ljósi þess að almennt er lítið til af tölvupóstagögnum og netöryggisgögnum yfirhöfuð. Þó ber að taka niðurstöðunum með varúð. Gæði gagnanna eru ábótavön. Íslensku gögnin eru að fullu sköpuð af gervigreind og virðast vera tiltölulega einsleit. Ekki er því hægt að fullyrða að þessar niðurstöður myndu endurspeglar frammistöðu flokkara á raunverulegum, nútímalegum netveiðipóstum. Verkefnið er grunntilraun á mikilvægu rannsóknar-efni og er ákall til frekara rannsóknar- og þróunarferlis, t.d. innan *FrostByte*, tölvuöryggisseturs Háskólans í Reykjavík og Háskóla Íslands, eða í samstarfi við CERT-IS og Miðeind.

Heimildir

- [1] M. Kosinski, *What Is a Cyberattack?*, <https://www.ibm.com/think/topics/cyber-attack>, 2026.
- [2] RÚV, *Spillibúnaður til netárása í 5000 íslenskum snjalltækjum*, <https://www.ruv.is/frettir/innlent/2026-03-16-spillibunadur-til-netarasa-i-5000-islenskum-snjalltaekjum-469957>, mar. 2026.
- [3] Zensec, *Phishing Statistics 2025–2026: The Numbers You Need to Know*, <https://zensec.co.uk/blog/2025-phishing-statistics-the-alarming-rise-in-attacks/>, mar. 2026.
- [4] Microsoft, *What Is Business Email Compromise (BEC)?*, <https://www.microsoft.com/en-gb/security/business/security-101/what-is-business-email-compromise-bec>.

- [5] L. Pajola, E. Caripoti, S. Banzer, S. Pizzi, M. Conti og G. Apruzzese, „E-PhishGEN: Unlocking Novel Research in Phishing Email Detection“, í *Proceedings of the 18th ACM Workshop on Artificial Intelligence and Security*, röð AISEC '25, Association for Computing Machinery, 2026, bls. 64–76, ISBN: 9798400718953. DOI: [10.1145/3733799.3762967](https://doi.org/10.1145/3733799.3762967). vefslóð: <https://doi.org/10.1145/3733799.3762967>.
- [6] P. Bountakas, K. Koutroumpouchos og C. Xenakis, „A Comparison of Natural Language Processing and Machine Learning Methods for Phishing Email Detection“, í *Proceedings of the 16th International Conference on Availability, Reliability and Security*, röð ARES '21, Vienna, Austria: Association for Computing Machinery, 2021, ISBN: 9781450390514. DOI: [10.1145/3465481.3469205](https://doi.org/10.1145/3465481.3469205). vefslóð: <https://doi.org/10.1145/3465481.3469205>.
- [7] J. Devlin, M.-W. Chang, K. Lee og K. Toutanova, *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*, 2019. arXiv: [1810.04805](https://arxiv.org/abs/1810.04805) [cs.CL]. vefslóð: <https://arxiv.org/abs/1810.04805>.
- [8] V. Sanh, L. Debut, J. Chaumond og T. Wolf, *DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter*, 2020. arXiv: [1910.01108](https://arxiv.org/abs/1910.01108) [cs.CL]. vefslóð: <https://arxiv.org/abs/1910.01108>.
- [9] V. Snæbjarnarson o.fl., „A Warm Start and a Clean Crawled Corpus - A Recipe for Good Language Models“, í *Proceedings of the Thirteenth Language Resources and Evaluation Conference*, N. Calzolari o.fl., ritstj., Marseille, France: European Language Resources Association, jún. 2022, bls. 4356–4366. vefslóð: <https://aclanthology.org/2022.lrec-1.464/>.
- [10] M. Eskandarian o.fl., *A Lightweight Defense Mechanism against Next Generation of Phishing Emails using Distilled Attention-Augmented BiLSTM*, 2026. arXiv: [2602.22250](https://arxiv.org/abs/2602.22250) [cs.CR]. vefslóð: <https://arxiv.org/abs/2602.22250>.
- [11] J. Gadsby og F. Sabrina, „A Review of the Use of Large Language Models to Generate Synthetic Cybersecurity Datasets“, í *2025 IEEE 35th International Telecommunication Networks and Applications Conference (ITNAC)*, 2025, bls. 1–7. DOI: [10.1109/ITNAC66378.2025.11302633](https://doi.org/10.1109/ITNAC66378.2025.11302633).
- [12] D. Sivanewaran, C. T. Hewage, H. Herath, R. S. Rathore, V. K. Singh og W. Jiang, „A systematic literature review of large language models in phishing attack generation and detection“, *Array*, árg. 30, bls. 100 775, 2026, ISSN: 2590-0056. DOI: <https://doi.org/10.1016/j.array.2026.100775>. vefslóð: <https://www.sciencedirect.com/science/article/pii/S2590005626000986>.
- [13] OWASP Foundation. „OWASP Top 10 for Large Language Model Applications v2.0“, Open WorldWide Application Security Project. vefslóð: <https://owasp.org/www-project-top-10-for-large-language-model-applications/>.
- [14] A. B. Sigurjónsson, *RAF620M-Lokaverkefni*, <https://github.com/axelbjarkar/RAF620M-Lokaverkefni>, 2026.
- [15] Wikipedia contributors, *Tf-idf — Wikipedia, The Free Encyclopedia*, 2026. vefslóð: <https://en.wikipedia.org/w/index.php?title=Tf%2%80%93idf&oldid=1348997568>.
- [16] T. Wolf o.fl., „Transformers: State-of-the-Art Natural Language Processing“, í *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, Association for Computational Linguistics, 2020. vefslóð: <https://www.aclweb.org/anthology/2020.emnlp-demos.6>.
- [17] L. Pajola, E. Caripoti, S. Pizzi, M. Conti, S. Banzer og G. Apruzzese, *Official Repository of E-PhishGen: Unlocking Novel Research in Phishing Email Detection*, <https://github.com/pajola/e-phishGen>, 2025.
- [18] Miðeind ehf., *Málfríður*. vefslóð: <https://mideind.is/is/vorur/malfridur>.